

OWASP LLM01 기반 프롬프트 인젝션 공격 동향

김민재[○], 이경률^{*}

[○]국립목포대학교 정보보호학과,

^{*}국립목포대학교 컴퓨터학부

e-mail: alswo807@mokpo.ac.kr[○], carpedm@mnu.ac.kr^{*}

Research Trends of Prompt Injection Attacks Based on OWASP LLM01

Minjae Kim[○], Kyungroul Lee^{*}

[○]Dept. of Information Security Engineering, Mokpo National University,

^{*}School of Computer Science and Engineering, Mokpo National University

● 요약 ●

대규모 언어 모델(Large Language Model, LLM)의 활용이 확산됨에 따라, 프롬프트 인젝션(prompt injection)이나 탈옥(jailbreak) 공격으로 인한 보안위협이 심각한 보안 문제로 부상하는 실정이다. 이에 본 논문에서는 OWASP(Open Web Application Security Project) Top 10 for LLM Applications(2025)의 LLM01 분류 체계를 기준으로, 2024년부터 2026년까지 공개된 주요 공격 연구에 대한 동향을 분석한다. 분석 결과, 최근 프롬프트 인젝션 공격은 단순한 프롬프트 변형부터, 전략 공간 확장, 검색 기반 공격, 모델 내부 상태 조작, 멀티모달 입력 활용과 같은 다양한 방향으로 발전하는 것으로 나타났으며, 일부 연구에서는 black-box 환경에서도 높은 공격 성공률을 가지는 것으로 보고됨으로써, 현재의 정렬(alignment) 및 가드레일 기반 방어 기술만으로는 충분히 대응하기 어렵다는 결론을 도출하였다. 본 논문의 결과는 LLM 보안 연구자 및 실무자에게 체계적인 공격 분류 기준과 방어 연구에 대한 방향성을 제공하기 위한 자료로 활용될 것으로 사료된다.

키워드: 프롬프트 인젝션(prompt injection), 탈옥 공격(jailbreak attack), OWASP Top 10 for LLM Applications 2025, LLM 보안(LLM security)

I. 서론

대규모 언어 모델(LLM)의 성능이 비약적으로 향상됨에 따라, GPT-4, Claude, Llama 등을 활용한 챗봇, 코딩 보조 도구, 자동화 시스템이 다양한 산업 분야에 빠르게 도입되는 실정이다. 그러나, 이와 동시에, LLM의 입력 해석 메커니즘을 악용함으로써, 시스템 지침을 무력화하거나 변조하여, 민감정보 유출, 무단 명령 실행, 안전 정책 우회와 같은 보안 위협을 유발하는 프롬프트 인젝션 및 탈옥 공격이 심각한 보안 문제로 부상하였다.

최근 연구들은 프롬프트의 문구, 구조, 표현 방식을 변형하는 것만으로도, 보안 정책이 적용된 최신 LLM을 효과적으로 우회함을 검증하였다. 이러한 결과는 LLM의 입력 처리 과정에 내재된 구조적인 취약점으로 인하여, 기존 방어 기법만으로는 효과적으로 대응하기에는 한계가 있다는 것을 의미한다.

이에 본 논문에서는 OWASP Top 10 for LLM Applications 2025의 LLM01(prompt injection)을 기준으로, 2024년부터 2026년

까지 공개된 프롬프트 인젝션 공격과 관련된 주요 연구 논문 9편을 분석하였으며, 공격 목표, 기법, 성능 및 한계 관점에서 연구 결과를 분석하고 비교하였다. 본 연구는 OWASP LLM Top 10에 대한 동향 분석의 첫 번째 단계로써, 향후, LLM02부터 LLM10까지 연구 동향을 분석할 예정이다.

II. 배경지식

1. OWASP 및 LLM Top 10

OWASP는 소프트웨어 보안 향상을 위한 비영리 단체로서, 다양한 보안 취약점 분류 체계와 가이드라인을 제공한다. 최근 챗봇, 검색 증강 생성(Retrieval-Augmented Generation, RAG), AI 에이전트 등 LLM 기반 서비스가 확산됨에 따라, 프롬프트 인젝션 학습 데이터

오염 민감정보 노출과 같은 기존의 웹 애플리케이션 보안 모델만으로는 설명하기 어려운 새로운 보안 위협이 등장하였다. 이에 OWASP는 LLM 환경에서의 주요 보안 위협에 대한 기준을 마련하기 위하여, OWASP Top 10 for LLM Applications를 공개하였다[10]. 본 논문에서는 LLM01(prompt injection)을 기준으로, 최근 프롬프트 인젝션 공격 연구에 대한 동향을 분석한다.

2. LLM01(prompt injection)

LLM01은 공격자가 입력을 통하여 모델의 지시 체계를 무력화하거나 변조하는 전반적인 공격을 포함한다. OWASP는 이러한 공격들을 공격 경로와 기법에 따라 총 9개의 세부 시나리오로 분류하였으며, 공격 시나리오 유형 예시를 [표 1]에 나타내었다.

3. 공격 시나리오 특징 분석

OWASP LLM01의 9개 공격 시나리오 예시는 공격 경로와 기법에 따른 특징을 가지며, 이러한 특징을 기반으로 공격 유형의 분류가 가능하다. 직접 인젝션(#1)과 적대적 접미사(#8)는 사용자가 모델에 직접 악성 입력을 전달하는 공격 방식이며, 간접 인젝션(#2)과 의도치 않은 인젝션(#3), 의도적 모델 영향(#4)은 외부 데이터나 지식 저장소를 매개체로 모델 동작에 영향을 미치는 공격 방식이다. 코드 인젝션(#5)과 페이로드 분할(#6)은 도구 연동 환경이나 실행 구조의 취약점을 활용하는 공격 방식으로, 모델 자체를 공격하기보다는 시스템 환경이 공격 대상인 특징을 가진다. 또한, 멀티모달 인젝션(#7)은 이미지나 음성 등 비텍스트 입력을 이용하며, 다국어/난독화 공격(#9)은 인코딩이나 문자 변환을 통하여 탐지를 회피한다.

이러한 분류는 프롬프트 인젝션을 단일 공격 유형으로 간주하기보다는, 실제 LLM 서비스 환경에서 발생 가능한 다양한 공격 양상을 체계적으로 설명하기 위한 목적으로 구성된 것으로 판단된다. 또한, 사용자 입력, 외부 문서, 지식 저장소, 멀티모달 데이터 등 다양한 공격 경로를 포괄함으로써, LLM 환경에서 발생 가능한 프롬프트 인젝션 위협을 종합적으로 이해하기 위한 기준을 제공하는 것으로 사료된다.

III. LLM01 공격 연구 동향 분석

1. 분석 개요

분석 대상 연구는 직접 인젝션, 간접 인젝션, 페이로드 분할, 멀티모달 인젝션, 적대적 접미사, 다국어/난독화 공격 등 LLM01의 주요 공격 유형을 포함하는 연구로 선정하였으며, 최근 동향을 반영하기 위하여, 2024년 이후 발표된 주요 학술대회 논문과 최신 프리프린트(preprint)를 포함하였다. 각 연구는 공격 목표, 핵심 기법, 성능, 장점, 한계점을 기준으로 분석하였으며, 이를 OWASP LLM01의 세부 공격 시나리오에 매핑하였다. 이를 통하여, 최근 연구되는 프롬프트 인젝션 공격 유형과 각 공격의 적용 방식 및 효과를 체계적으로 분석하고 비교할 것으로 판단된다. [표 2]는 분석 대상 연구의 주요 특징을 비교하였다.

Table 1. LLM01 공격 시나리오 예시

No.	공격 유형	설명
#1	직접 인젝션	챗봇 입력창에 악성 프롬프트를 직접 입력함으로써, 시스템 지침 무력화 및 권한 상승 유도
#2	간접 인젝션	웹페이지나 이메일 등 외부 소스에 숨겨진 명령을 삽입하는 경우, LLM이 이를 해석하고 실행함
#3	의도치 않은 인젝션	악의가 없는 문구가 의도하지 않게 LLM의 동작을 변경하여, 예상하지 못한 결과를 유발하는 비의도적인 경우
#4	의도적 모델 영향	RAG 저장소 문서를 사전에 변조함으로써, 검색 시, 오염된 출력을 생성하도록 유도함
#5	코드 인젝션	LLM 연동 도구의 취약점을 이용하여, 악성코드 실행을 유도함
#6	페이로드 분할	악성 명령을 여러 입력에 분산하여 삽입한 후, LLM이 이를 결합 및 실행하도록 유도함
#7	멀티모달 인젝션	이미지나 음성 등 비텍스트 입력에 숨겨진 프롬프트를 삽입하여, 모델의 동작을 조작함
#8	적대적 접미사	의미 없는 특수 문자열을 추가하여, 안전 필터를 우회하고, 유해 응답을 유도함
#9	다국어/난독화 공격	Base64, 이모지, ASCII Art 등으로 명령을 인코딩하여, 탐지 시스템을 우회함

2. 직접 인젝션 공격 (#1)

Breaking the Ceiling[1]은 탈옥 전략을 4개 요소로 분해한 뒤, 유전 알고리즘을 활용하여, 최적 조합을 도출하는 공격 기법을 제안하였다. 해당 기법은 Claude-3.5를 대상으로, 87~96%의 높은 Jailbreak Success Rate(JSR)를 달성하였으며, 모델 내부 정보 없이, 다른 모델에서 탐색한 전략을 목표 모델로 전이가 가능한 장점을 가진다. 그러나, 최적 조합을 탐색하는 과정에서 반복적인 질의가 요구되어, 공격 비용이 높다는 한계점이 존재한다.

Token-Efficient Prompt Injection Attack[2]은 토큰 압축을 통하여, LLM의 추론 과정을 중단시키는 공격 기법을 제안하였다. 실험 결과, 압축률 48%와 ASR(Attack Success Rate) 34%의 성능을 가지며, 비교적 적은 토큰으로도 공격이 가능한 장점이 있다. 반면, 공격 결과가 주로 응답 실패 수준에 머무르며, 특정 추론 모델에 대한 의존성이 요구되는 한계점이 존재한다.

Benign Data Mirroring[3]은 타겟 모델에 무해한 질문에 해당하는 응답을 수집하고, 이 응답을 기반으로, 별도의 모델을 정렬함으로써, 타겟 모델을 모방하는 미러 모델 구축 기법을 제안하였다. 이 기법은 ASR을 80~92%로 유지하면서, 공격 탐지 가능성을 낮추는 특징이 있다. 다만, 양성 데이터 정렬에 따른 모델 간 유사성과 관련된 이론적 근거는 부족하며, 주로 실증적 검증을 기반으로 결과를 도출하였다.

3. 간접 인젝션 및 RAG 공격 (#2)

TopicAttack[4]은 공격 프롬프트를 직접 삽입하는 대신, 주제 전환(topic transition)을 이용하여, 대화 문맥을 점진적으로 조작하는 간접 인젝션 기법을 제안하였다. 실험 결과, 방어가 미적용된 소형

Table 2. LLM01 연구 동향의 세부 분류에 따른 공격 목표, 핵심 기법, 성능, 장점, 한계점 비교

참고 문헌	세부 분류	공격 목표	핵심 기법	성능	장점	한계점
[1]	[#1]직접 인젝션	유해 응답 생성	기존 jailbreak 4요소 분해 + 유전 알고리즘 기반 최적 조합 탐색	(Claude-3.5) JSR: 87~96%	모델 정보 없이 다른 모델로 전이 가능	반복 질의 비용 높음, 방어 시스템에 의한 탐지 가능성 증가
[2]	[#1]직접 인젝션	LLM 추론 중단 및 응답 실패 유도	토큰 압축 기반 reasoning 중단 유도	압축률: 48% ASR: 34%	저비용 및 고효율 공격, 자동화 가능	단순 응답 실패, 환경/모델 의존성 존재
[3]	[#1]직접 인젝션	유해 응답 생성	미러 모델 기반 공격 탐색 은닉	ASR: 80~92% (평균 1.5회 노출)	높은 은밀성 제공	양성 데이터로 생성된 미러 모델에 따른 타겟 모델의 모방 효과 및 이론적 근거 부족
[4]	[#2]간접 인젝션	모델 행동 조작	주제 전환 기반 문맥 조작	(소형 모델+방어 미적용) ASR: 87~99%	패턴 탐지 우회 + 방어로부터 견고함	특정 모델 및 방어 조합에서 ASR이 1% 미만으로 매우 감소함
[5]	[#2]간접 인젝션	명령 실행 유도	트리거 조각 + 공격 조각 분리 최적화	ASR: 58% 이메일 실증: 80%	최소한의 오염으로 공격 가능	키워드 기반 등 다른 검색 방식에 대한 검증 필요
[6]	[#7]멀티모달 인젝션	모델 행동 조작	SAM 영역 탐색 + 영역 평균 색상 렌더링	기본 설정+은닉: 100% 스텔스 설정: 64%	black-box 자동화 가능	실제 은닉이 필요한 환경에서 성공률이 매우 감소함
[7]	[#8]적대적 접미사	유해 응답 생성	내부 거절 태도 약화 + 적대적 접미사 생성	AdvBench: 77.1% 확장: 92.2%	기존 템플릿 기반 공격보다 내부 표현 조작이 효과적임	white-box 공격으로, 내부 접근 필요
[8]	[#9]다국어/난독화 공격	유해 응답 생성	금지어를 ASCII Art로 인코딩	HPR: 84% HS: 3.6 ASR: 52%	명시적으로 유해 키워드 노출 없이 공격 가능	모델의 문자 인식 능력에 따라 성공률이 의존적임
[9]	[#9]다국어/난독화 공격	가드레일 우회	문자 인젝션 12종 + AML 회피 8종	문자 인젝션: 20~92% AML: 2.8~95.2%	텍스트 변형만으로 가드레일 우회 가능	우회 성공이 공격 성공을 의미하는 것은 아님, 가드레일에 따른 큰 편차 발생

모델 환경에서는 87~99%의 높은 공격 성공률(ASR)을 달성하였으며, 방어가 적용된 환경에서도 대체로 높은 ASR을 유지하였다. 다만, 특정 모델과 특정 방어 기법(Llama3-8B-Instruct+SecAlign)이 결합된 환경에서는 ASR이 1% 미만으로 매우 감소함으로써, 모델에 의존적인 것으로 판단된다.

Overcoming the Retrieval Barrier[5]는 검색을 보장하는 트리거 조각과 공격 명령을 포함하는 페이로드 조각을 분리함으로써, 최적화하는 기법을 제안하였다. 이를 통하여, 단일 이메일만으로도 악성코드 실행을 최대 80%까지 유도하였다. 그러나, 특정 검색 환경인 Dense Retriever에서만 검증한 한계점이 존재하는 것으로 판단된다.

4. 멀티모달 인젝션 공격 (#7)

Image-based Prompt Injection[6]은 SAM(Segment Anything Model) 기반 자동 영역 탐색과 배경 매칭 텍스트 렌더링을 통하여, 이미지 내부에 공격 명령을 삽입하는 기법을 제안하였다. 실험 결과, 12종의 공격 프롬프트 중, 가장 우수한 성능을 보인 프롬프트를 기준으로, 기본 설정에서는 100%, 스텔스 설정에서는 64%의 성공률을 가지는 것으로 나타났다. 이는 공격의 은밀성이 높아질수록, 성공률이 감소하는 상충관계가 존재한다는 한계점을 가지는 것으로 판단된다.

5. 적대적 접미사 (#8)

Internal Stance Manipulation[7]은 모델이 유해 요청에 따른 거절 응답을 생성하기 직전에 내부적으로 거절 방향성을 약화시키는 적대적 접미사 생성 기법을 제안하였다. AdvBench를 기준으로, 77.1%의 공격 성공률을 가지는 것으로 나타났으며, 확장 실험에서는 92.2%까지 성능이 향상되었다. 다만, 모델 내부 정보에 접근이 가능한 white-box 환경을 전제함에 따라, 폐쇄형 상용 모델에는 적용이 어려운 한계점이 존재한다.

6. 다국어/난독화 공격 (#9)

ArtPrompt[8]는 금지어를 ASCII Art 형태로 변환하여, 모델의 안전 정책을 우회하는 공격 기법을 제안하였다. 실험 결과, HPR(Helpful Rate) 84%, HS(Harmfulness Score) 3.6, ASR 52%의 성능을 가지는 것으로 나타났으나, 공격 성공 여부가 모델의 문자 인식 능력에 크게 의존하는 한계점이 존재한다.

Bypassing LLM Guardrails[9]는 문자 변형 기반 인젝션 기법 12종과 AML(Adversarial Machine Learning) 회피 기법 8종을 각각 활용하여, 상용 가드레일의 우회 성능을 평가하였다. 실험 결과, 문자 인젝션은 20~92%, AML 회피 기법은 2.7~95.2% 수준의 우회율을 가지는 것으로 나타나, 가드레일에 따라 편차가 크다는 특징을 보였다. 또한, 가드레일 우회가 실제 유해 응답 생성이나 공격 성공을 의미하는 것은 아니라는 한계점이 존재한다.

IV. 결론

본 논문에서는 OWASP LLM01 분류 체계를 기준으로, 2024년부터 2026년까지 공개된 프롬프트 인젝션 및 탈옥 공격과 관련된 주요 연구 논문 9편을 대상으로, 연구 동향을 분석하였다. 분석 결과, 최근 프롬프트 인젝션 공격은 단순한 프롬프트 변형부터, 전략 공간 확장, 검색 기반 공격, 모델 내부 상태 조작, 멀티모달 입력 활용과 같이, 다양한 방향으로 발전하는 것으로 판단된다. 또한, 일부 연구에서는 black-box 환경에서도 높은 공격 성공률을 가지는 것으로 나타났으며, 이는 현재의 정렬(alignment) 및 가드레일 기반 방어만으로는 다양한 공격 유형에 효과적으로 대응하기 어려운 한계점을 가지는 것으로 판단된다. 특히, 분석 대상 연구들로부터 공격 경로와 입력 형태가 점차 다양해지는 경향이 나타났으며, 이는 프롬프트 인젝션이 단순한 입력 조작을 넘어, RAG, 에이전트, 멀티모달 시스템 등 LLM 활용 환경 전반에서 고려되어야 할 보안 위협임을 시사한다. 본 연구는 OWASP LLM01에 포함되는 프롬프트 인젝션 공격을 중심으로 최신 연구 동향을 분석하였으며, 향후, 민감정보 노출(LLM02), 공급망 취약점(LLM05) 등 다른 OWASP LLM Top 10에 대한 연구 동향을 분석함으로써, 전반적인 LLM 보안 위협에 동향을 체계적으로 분석할 예정이다.

ACKNOWLEDGEMENT

이 연구는 2025년도 산업통상자원부 및 산업기술기획평가원(KEIT) 연구비 지원에 의한 연구임(‘RS-2025-02317682’). 본 과제(결과물)는 2026년도 교육부 및 전라남도의 재원으로 전라남도RISE센터의 지원을 받아 수행된 지역혁신중심 대학지원체계(RISE)의 결과입니다. (2026-RISE-14-001)

REFERENCES

- [1] Y. Huang, Y. Sun, S. Ruan, Y. Zhang, Y. Dong, and X. Wei, "Breaking the Ceiling: Exploring the Potential of Jailbreak Attacks through Expanding Strategy Space," Findings of the Association for Computational Linguistics: ACL 2025, pp. 7870-7888, Jul. 2025.
- [2] Y. Cui, Y. Cai, and Y. Wang, "Token-Efficient Prompt Injection Attack: Provoking Cessation in LLM Reasoning via Adaptive Token Compression," arXiv preprint arXiv:2504.20493, 2025.
- [3] H. Mu, H. He, Y. Zhou, Y. Feng, Y. Xu, L. Qin, X. Shi, Z. Liu, X. Han, Q. Shi, Q. Zhu, and W. Che, "Stealthy Jailbreak Attacks on Large Language Models via Benign Data Mirroring," Proc. NAACL-HLT 2025, pp. 1784-1799,

- Apr. 2025.
- [4] Y. Chen, H. Li, Y. Li, Y. Liu, Y. Song, and B. Hooi, "TopicAttack: An Indirect Prompt Injection Attack via Topic Transition," Proc. EMNLP 2025, pp. 7327-7345, Nov. 2025.
- [5] H. Chang, E. Bao, X. Luo, and T. Yu, "Overcoming the Retrieval Barrier: Indirect Prompt Injection in the Wild for LLM Systems," arXiv preprint arXiv:2601.07072, 2026.
- [6] N. Nagaraja, L. Zhang, Z. Wang, B. Zhang, and P. Patil, "Image-based Prompt Injection: Hijacking Multimodal LLMs through Visually Embedded Adversarial Instructions," arXiv preprint arXiv:2603.03637, 2026.
- [7] S. Fu, D. Su, B. Huang, F. Sun, J. Wang, W. Chen, H. Shen, and X. Cheng, "Jailbreak LLMs through Internal Stance Manipulation," Proc. EMNLP 2025, pp. 15444-15459, Nov. 2025.
- [8] F. Jiang, Z. Xu, L. Niu, Z. Xiang, B. Ramasubramanian, B. Li, and R. Poovendran, "ArtPrompt: ASCII Art-based Jailbreak Attacks against Aligned LLMs," Proc. 62nd Annual Meeting of the Association for Computational Linguistics (ACL), pp. 15157-15173, Aug. 2024.
- [9] W. Hackett, L. Birch, S. Trawicki, N. Suri, and P. Garraghan, "Bypassing LLM Guardrails: An Empirical Analysis of Evasion Attacks against Prompt Injection and Jailbreak Detection Systems," Proc. The First Workshop on LLM Security (LLMSEC), pp. 101-114, Aug. 2025.
- [10] OWASP Foundation, "OWASP Top 10 for Large Language Model Applications 2025," <https://genai.owasp.org>, 2025.